Webscraping

Jan-Philipp Kolb

Wed Oct 14 11:19:52 2015

Das R-Paket XML

Gaston Sanchez - Basics of XML and HTML

```
# install.packages("XML")
library(XML)
```

Einlesen einer Tabelle mit der Funktion readHTMLTable: Beispieldaten für die Bundesländer

```
BLA_link <- "http://www.bernhard-gaul.de/wissen/bundeslaend
BLA_tab <- readHTMLTable(BLA_link)
```

Überblick über die Daten

BLA_tab	<- BLA_tab[[1]]		
Wappen	Land	Fläche (km²)	Einwohner
Wappen	Land	Fläche (km²)	Einwohner
	Baden-Württemberg	35 751,36	10 569 111
	Bayern	70 550,23	12 519 571
	Berlin	891,70	3 375 222
	Brandenburg	29 485,63	2 449 511
	Bremen	419,24	654 774
	Hamburg	755,30	1 734 272
	Hessen	21 114,93	6 016 481
	Mecklenburg-Vorpommern	23 210.55	1 600 327
	Niedersachsen	47 613,78	7 778 995
	Nordrhain Wastfalan	24 100 70	17 554 220

Nordrhein-Westfalen 34 109,70 17 554 329

Rheinland-Pfalz 19 854,10 3 990 278

Saarland 2 568,70 994 287 Sachsen 18 420,01 (3) 4 1050 204 (4)

Daten bearbeiten

Die erste und 18. Zeile entfernen:

$$BLA_tab \leftarrow BLA_tab[-c(1,18),-1]$$

Die Daten editieren

```
mean(BLA_tab[,2])

## Warning in mean.default(BLA_tab[, 2]): argument is not in
## returning NA

## [1] NA

um dies zu ändern ist ein wenig Kosmetik notwendig:
PLA_tab[_2] <- gaph(#_#_BLA_tab[_2])
```

```
BLA_tab[,2] <- gsub(" ","",BLA_tab[,2])
BLA_tab[,2] <- gsub(",",".",BLA_tab[,2])
BLA_tab[,2] <- as.numeric(BLA_tab[,2])</pre>
```

```
mean(BLA_tab[,2])
```

```
## [1] 22323
```

Die weiteren Spalten bearbeiten

```
BLA_tab[,3] <- as.numeric(gsub(" ","",BLA_tab[,3]))
BLA_tab[,4] <- as.numeric(gsub(" ","",BLA_tab[,4]))</pre>
```

Das Editing ist also aufwändiger als das eigentliche Scraping

Die Daten speichern

```
write.csv(BLA_tab,file="BLA_tab.csv")
```

Das Paket rvest

```
install.packages("rvest")
```

```
library("rvest")
link <- "https://de.wikipedia.org/wiki/Liste der St%C3%A4d-
link_data <- read_html(link)</pre>
# parse the document for R representation:
mps.doc <- htmlParse(link_data)</pre>
# get all the tables in mps.doc as data frames
mps.tabs <- readHTMLTable(mps.doc)</pre>
```

Links

Beispiel: GiventheData

Five easy steps for webscraping

Reference XML

```
citation("XML")
##
## To cite package 'XML' in publications use:
##
##
     Duncan Temple Lang and the CRAN Team (2016). XML: Too.
##
     Parsing and Generating XML Within R and S-Plus. R pack
     version 3.98-1.4. https://CRAN.R-project.org/package=
##
##
##
   A BibTeX entry for LaTeX users is
##
     @Manual{.
##
##
       title = {XML: Tools for Parsing and Generating XML \
       author = {Duncan Temple Lang and the CRAN Team},
##
##
       vear = \{2016\}.
       note = {R package version 3.98-1.4},
##
       url = {https://CRAN.R-project.org/package=XML},
##
                                      4日 → 4団 → 4 豆 → 4 豆 → 9 Q ○
##
```

Reference rvest

```
citation("rvest")
##
  To cite package 'rvest' in publications use:
##
##
     Hadley Wickham (2015). rvest: Easily Harvest (Scrape)
##
     R package version 0.3.1.
     https://CRAN.R-project.org/package=rvest
##
##
   A BibTeX entry for LaTeX users is
##
##
     @Manual{.
##
       title = {rvest: Easily Harvest (Scrape) Web Pages},
       author = {Hadley Wickham},
##
##
       year = \{2015\},\
       note = {R package version 0.3.1},
##
       url = {https://CRAN.R-project.org/package=rvest},
##
                                      <ロト < 個 ト < 重 ト < 重 ト ■ ■ 9 Q @
##
```